

Reconciliación de MTOs · Tornillería

Bernabé Muñoz · Caso técnico Senior FDE · Septiembre 2026

1. El problema y el KPI

El cuello de botella no es la precisión de un modelo: es la **asimetría de coste**. Dar por buena una fila mal extraída cuesta de tres a ocho semanas de obra; mandar a revisión una buena cuesta noventa segundos de comprador. El cociente ronda **1:50.000**, y de ahí sale toda la arquitectura: adivinar sólo compensaría si nos equivocáramos menos de una vez cada cincuenta mil, y ningún criterio plausible llega ahí. **El sistema no adivina nunca**. Cada valor está escrito en el MTO o se deduce por una regla que no admite alternativa. Lo demás va a revisión.

Me comprometo a una tasa de escape por debajo del 1,5 %. Sobre 200 filas no vistas el escape medido fue **0**; con esa muestra el límite superior honesto al 95 % es 1,5 %, y ése es el número que defendiendo, no el cero.

La cobertura la fija vuestro dato, no mi sistema: 43 % en vuestro MTO, 74 % en filas con datos completos. La diferencia es que ninguna arandela de vuestras quince filas trae dureza.

El umbral no lo he elegido yo: es 100. Cada celda lleva una confianza que calcula el código como el mínimo de cuatro hechos medidos —procedencia, verificación del literal contra el texto, acuerdo de segmentación y coherencia cruzada—. **RESUELTA** es exactamente `confianza == 100`. O el valor viene por un camino que no puede estar mal, o lo mira una persona.

2. La solución, componente a componente

Componente	Tipo	Qué le pasa al KPI si lo quito
Segmentador — parte la prosa en piezas	LLM ×1	Se caen las 9 filas de set: 18 de 30 líneas
Normalizador — 26 normas, 21 calidades, 7 acabados, 5 nombres	Tabla	Nada si lo cambio por otra tabla; todo si lo cambio por un modelo
Derivaciones — calidad→material 21/21, norma→nombre 25/25	Tabla	Material cae de 20/20 a 17/20
11 coherencias + 8 invariantes	Código	Sube el escape: es la red de seguridad entera
Extractor por elemento	descartado	Con catálogos cerrados, buscar por token lo hace igual y sin llamadas
Árbitro de ambigüedad	descartado	Subiría cobertura y subiría el escape. 1:50.000 lo mata
Autoconsistencia ×3	descartada	Medido: 0 desacuerdos en 15 filas a temperatura 0 y 0,7

Un solo agente en producción. Los otros tres los descarté midiendo, no opinando. La autoconsistencia estaba en mi diseño como pilar: la construí, la medí con 90 llamadas reales y la quité, porque el factor de confianza que alimentaba valía siempre 100 —sugería una protección que no existía.

Dos propiedades hacen la alucinación estructuralmente imposible, no improbable: **el modelo nunca ve los catálogos** —dice qué pone, el código decide qué significa— y **se le pide texto literal, no posiciones**, que el código localiza y verifica contra el origen. Si un trozo no aparece tal cual, se descarta.

3. Resultados

Vuestro MTO, 15 filas → 30 líneas. Cobertura 43,3 % · **escape 0 %** · segmentación 100 % · los siete atributos al 100 %.

Ruido de revisión: 0 %. De las 17 líneas en revisión, **las 17 son dato que el MTO no trae**. Ninguna es duda del sistema. La cobertura no la limita el sistema: la limita que vuestra ingeniería no escribe la dureza de las arandelas.

Blind set propio de 300 filas no vistas, con formatos reales de proveedor de tubería: 200 compuestas con verdad conocida dan **escape 0,0 %**; 100 adversarias —normas inventadas, calidades inexistentes, nombres de pieza inventados, cuatro filas que ni son tornillería— dan **0 invenciones**.

Dónde falla: de los fallos por atributo, prácticamente todos son "no extrajo nada" y casi ninguno "extrajo mal". **El modo de fallo es la omisión, no la invención.** Las que se caen son los formatos que **no nombran la pieza principal** —3/4" IN DIA X 200MM LONG, FULLY THREADED, C/W 2 HEAVY HEXAGON NUTS—: un comprador deduce que es un espárrago, el sistema se niega a ponerle nombre. Y las descripciones en portugués o alemán, que se arreglan añadiendo filas a una tabla, no reentrenando nada.

Coste y latencia: 0,0008 \$ y 0,83 s por fila. Una obra completa —100.000 filas en 25 revisiones— sale por **unos 80 \$ de modelo**, frente a las ~2.500 horas de comprador que hoy cuesta leerlas.

4. La solución objetivo

El histórico de respuestas. Vuestra respuesta —que la calidad que falta se consulta con ingeniería— cambia dónde está el valor. La misma arandela sin dureza aparece en la revisión 9, en la 12 y en la 15, y hoy se pregunta tres veces. Con clave canónica exacta se pregunta **una** y las otras veinticuatro la heredan: con 25 revisiones por obra, eso no reduce el coste de la consulta, lo divide. Diseñado y especificado; no construido.

Aprendizaje del vocabulario por origen, midiendo la tasa de revisión de cada estudio y ampliando catálogos donde duele. **Y procesado por lotes**, que baja el coste a la mitad y quita el techo de latencia.

5. Qué he decidido no hacer

No derivar lo que no es deducción. El 130 sin unidad de un espárrago ASTM parece milímetros, y probablemente lo es —pero ASTM admite las dos unidades, así que es una suposición. Va a revisión y me cuesta tres líneas de treinta: **diez puntos de cobertura pagados a conciencia.**

No completar sets por convención, no usar coincidencia difusa en ninguna parte —DIN 9331 no se convierte en DIN 933—, y no integrarme con vuestra base de compras, que necesita una conversación pendiente.

Y no construir tres de los cuatro agentes que había diseñado. Los medí primero.

6. Qué rompe esto en producción

La deriva del vocabulario. Un estudio nuevo escribe distinto y la cobertura cae sin avisar. Necesita monitor de tasa de revisión por origen.

Que vuestra base de compras esté sucia. Normalizaría impecablemente contra un vocabulario que aguas abajo no cuadra: el sistema correcto y el resultado inútil.

La erosión de la cola. Si la revisión crece, el comprador aprueba en bloque y el escape entra igual. Es riesgo de proceso: la interfaz no debe permitir aprobar en bloque motivos distintos, y hace falta muestreo de auditoría. Hoy el ruido es 0 % y ése es el número a vigilar.

45 commits · 181 tests · Arranca en frío con un comando.